

Tratamento de Lixo - Dataset

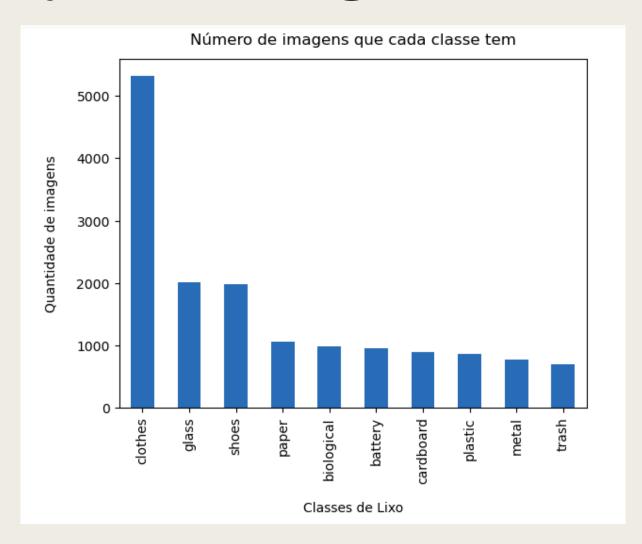
- Total de 15515 exemplos;
- 12 classes;
- Problema de classificação;
- Não é balanceado.

Ajustes no Dataset

- battery
- biological
- brown-glass
- cardboard
- clothes
- green-glass
- metal
- paper
- plastic
- shoes
- trash
- mwhite-glass

- battery
- 🛅 biological
- cardboard
- clothes
- 🛅 glass
- 🛅 metal
- paper
- plastic
- shoes
- trash 🔳

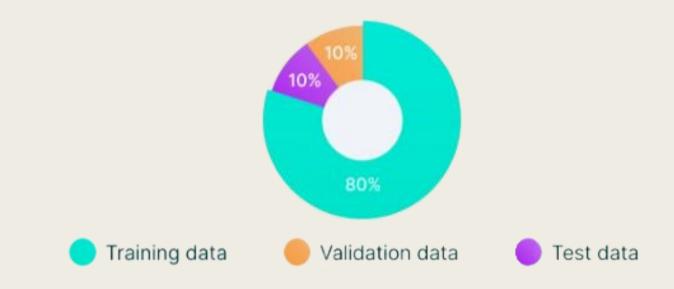
Distribuição das imagens pelas classes



Construção da Rede Neuronal

```
# mobilenetv2 é um modelo (deep learning) do tipo CNN que é pré-treinado, ou seja,
# já foi treinada para classificar imagens, sendo esta capaz de classificar
# 1000 categorias das mesmas
mobilenetv2 layer = mobilenetv2.MobileNetV2(include top = False, input shape = (IMAGE WIDTH, IMAGE HEIGHT,IMAGE CHA
                       weights = 'imagenet')
# O modelo mobilenetv2 já está pré-treinado, logo, não queremos que estas camadas que ele tras
# sejam treinadas novamente pelo tensorflow
mobilenetv2 layer.trainable = False
model = Sequential()
model.add(keras.Input(shape=(IMAGE WIDTH, IMAGE HEIGHT, IMAGE CHANNELS)))
# Cria uma camada para aplicar o preprocessamento na imagem, para ter as caracteristicas pretendidas
def mobilenetv2 preprocessing(img):
  return mobilenetv2.preprocess input(img)
model.add(Lambda(mobilenetv2 preprocessing))
#model.add(tf.keras.layers.BatchNormalization()) | Demora mt tempo a treinar com esta camada +/- 15 por epoch
# Camadas pre treinadas
model.add(mobilenetv2 layer)
model.add(tf.keras.layers.GlobalAveragePooling2D())
model.add(Flatten(name="featuresCamadaFlatten"))
model.add(tf.keras.layers.Dropout(0.3))
model.add(Dense(len(categories), activation='softmax'))
model.compile(loss='categorical crossentropy', optimizer='adam', metrics=['categorical accuracy'])
model.summary()
feature extractor = keras.Model(
    inputs=model.inputs,
    outputs=model.get layer(name="featuresCamadaFlatten").output,
x = tf.ones((1, 224, 224, 3))
features = feature extractor(x)
print("Número de Features da Camada featuresCamadaFlatten:")
print(features)
```

Divisão em Treino, Validação e Teste



Num Imagens de Treino = 12412 Num Imagens de Validação = 1551 Num Imagens de Teste = 1552

Softmax

Data Augmentation - Teste

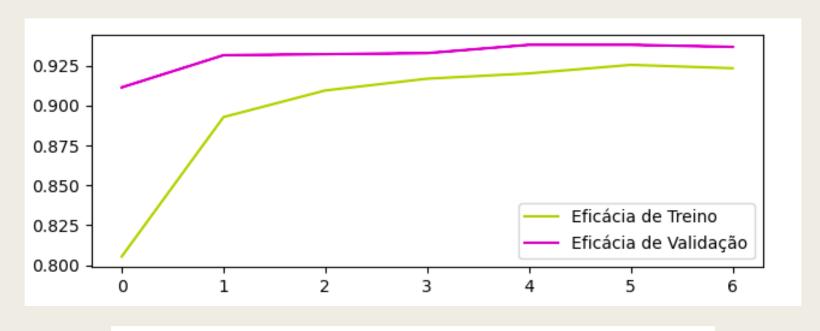
GlobalAveragePooling2D

```
Epoch 1/20
0.3179 - val categorical accuracy: 0.9115
Epoch 2/20
0.2730 - val categorical accuracy: 0.9219
Epoch 3/20
0.2535 - val categorical accuracy: 0.9219
Epoch 4/20
0.2452 - val categorical accuracy: 0.9277
Epoch 5/20
0.2477 - val categorical accuracy: 0.9290
Epoch 6/20
0.2529 - val categorical accuracy: 0.9277
Epoch 7/20
0.2194 - val categorical accuracy: 0.9362
Epoch 8/20
0.2238 - val categorical accuracy: 0.9336
Epoch 9/20
ights from the end of the best epoch: 7.
0.2227 - val categorical accuracy: 0.9323
Epoch 9: early stopping
```

Softmax

Data Augmentation - Teste

GlobalAveragePooling2D



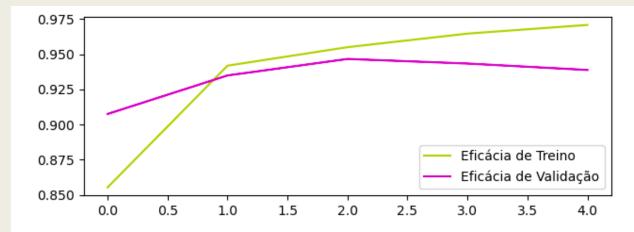
Eficácia de teste = 93.69 %

Softmax

Data Augmentation - Teste

GlobalAveragePooling2D

```
Epoch 1/20
0.2689 - val categorical accuracy: 0.9076
Epoch 2/20
0.2049 - val categorical accuracy: 0.9349
Epoch 3/20
0.1789 - val categorical accuracy: 0.9466
Epoch 4/20
0.1821 - val categorical accuracy: 0.9434
Epoch 5/20
ights from the end of the best epoch: 3.
0.1680 - val categorical accuracy: 0.9388
Epoch 5: early stopping
```



Eficácia de teste = 94.33 %

Flatten - Teste

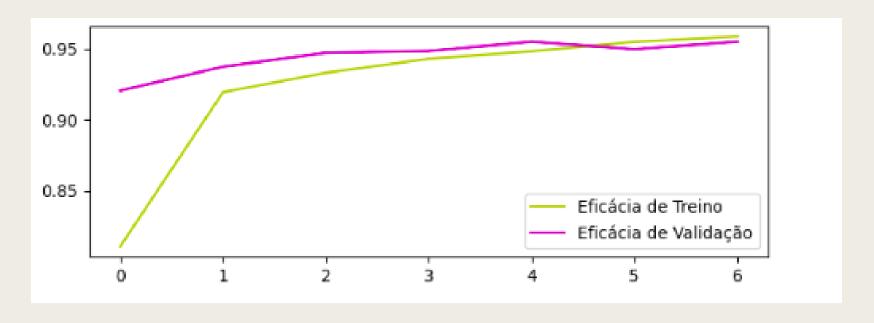
```
model.add(Flatten(name="featuresCamadaFlatten"))
#model.add(tf.keras.layers.GlobalAveragePooling2D(name="featuresCamadaGlobal"))
model.add(Dense(len(categories), activation='softmax'))
      0.975
      0.950
      0.925
                                                     Eficácia de Treino
      0.900
                                                     Eficácia de Validação
                   Eficácia de teste = 93.69 %
```

GlobalAveragePooling2D + Relu Flatten + Relu

Eficácia de teste = 5.8 %

Eficácia de teste = 6.51 %

GlobalAveragePooling2D + Flatten + Dropout + Softmax



Eficácia de teste = 94.85 %

Previsões

Número de vezes que a classe bateria apareceu no conjunto de dados.

	support
battery	85
biological	104
cardboard	87
clothes	539
glass	200
metal	69
paper	114
plastic	99
shoes	191
trash	64
accuracy	0.95 1552
accuracy	0.33 1332

Conclusão

Se cada ecoponto tivesse uma camara, este modelo seria capaz de reconhecer qual o objeto que está a ser despejado e se este está a ser colocado ou não no sítio certo.